

EM 算法

EM 算法

概率模型有时既有观测变量,又有隐变量或潜在变量。如果概率模型的变量全是观测变量,那么给定数据可以直接用极大似然估计法,或贝叶斯估计法估计模型参数。但是,当模型含有隐变量时,就不能简单地使用这些估计方法。EM 算法就是含有隐变量的概率模型参数极大似然估计法。

三硬币模型

假设有 3 枚硬币,分别记作 A, B, C。这些硬币正面出现的概率分别是 π , p 和 q 。

进行如下硬币试验:

先掷硬币 A, 根据其结果, 选掷硬币 B 或硬币 C, 正面选硬币 B, 反面选硬币 C; 然后掷选出的硬币, 掷硬币的结果, 出现正面记作 1, 出现反面记作 0; 独立地重复 n 次实验, n 次观测结果如下: 1, 1, 0, 1, 0, 0, 1, 0, 1, 1。

假设只能观测到掷硬币的结果, 不能观测硬币的过程, 问如何估计三硬币正面出现的概率, 即三硬币模型的参数。

解: 对每一次试验可以进行如下建模

$$\begin{aligned} P(Y|\theta) &= \sum_z P(Y, z|\theta) = \sum_z P(z|\theta) P(Y|z, \theta) \\ &= P(z=1|\theta) P(Y|z=1, \theta) + P(z=0|\theta) P(Y|z=0, \theta) \\ &= \begin{cases} \pi p + (1-\pi)q, & \text{if } Y=1 \\ \pi(1-p) + (1-\pi)(1-q), & \text{if } Y=0, \end{cases} \\ &= \pi p^Y (1-p)^{1-Y} + (1-\pi) q^Y (1-q)^{1-Y} \end{aligned}$$

其中, 随机变量 Y 是观测变量, 每一次试验观测的结果是 1 或 0;

随机变量 z 是隐变量, 表示未观测到的掷硬币 A 的结果;

$\theta = (\pi, p, q)$ 是模型参数, 将观测数据表示为

$$Y = (Y_1, Y_2, \dots, Y_n), \text{ 未观测数据表示为 } Z = (Z_1, Z_2, \dots, Z_n)^T$$

观测数据的似然函数为:

$$\begin{aligned} P(Y|\theta) &= \sum_z P(Z|\theta) P(Y|Z, \theta) = \prod_{j=1}^n P(Y_j|\theta) \\ &= \prod_{j=1}^n [\pi p^{Y_j} (1-p)^{1-Y_j} + (1-\pi) q^{Y_j} (1-q)^{1-Y_j}] \end{aligned}$$

求模型参数 $\theta = (\pi, p, q)$ 的极大似然估计, 即使用对数似然函数求参数估计可得:

$$\begin{aligned} \theta &= \arg \max_{\theta} \ln P(Y|\theta) \\ &= \arg \max_{\theta} \ln \prod_{j=1}^n [\pi p^{Y_j} (1-p)^{1-Y_j} + (1-\pi) q^{Y_j} (1-q)^{1-Y_j}] \\ &= \arg \max_{\theta} \sum_{j=1}^n \ln [\pi p^{Y_j} (1-p)^{1-Y_j} + (1-\pi) q^{Y_j} (1-q)^{1-Y_j}] \end{aligned}$$

EM的导出

Jensen (琴生) 不等式:

若 f 是凸函数, 则:

$$f(tx + (1-t)x_0) \leq tf(x) + (1-t)f(x_0)$$

其中 $t \in [0, 1]$ 。同理, 若 f 是凹函数, 则只需将式中的 \leq 换成 \geq 即可。

将上式中的 t 推广到 n 个同样成立, 也即:

$$f(tx_1 + tx_2 + \dots + tx_n) \leq tf(x_1) + tf(x_2) + \dots + tf(x_n)$$

其中 $t_1, t_2, \dots, t_n \in [0, 1]$ 。同理, 若 f 是凹函数, 则只需将式中的 \leq 换成 \geq 即可。

将上式中的 t 推广到 n 个同样成立, 也即:

$$f(t_1x_1 + t_2x_2 + \dots + t_nx_n) \leq t_1f(x_1) + t_2f(x_2) + \dots + t_nf(x_n)$$

其中 $t_1, t_2, \dots, t_n \in [0, 1]$, $t_1 + t_2 + \dots + t_n = 1$ 。在概率论中常以以下形式出现:

$$\varphi(E[X]) \leq E[\varphi(X)]$$

其中, X 是随机变量, φ 是凸函数, $E[X]$ 表示 X 的期望

$$L(\theta) = \ln p(Y|\theta) = \ln \sum_z p(Y, z|\theta) = \ln \left(\sum_z p(Y|z, \theta) p(z|\theta) \right)$$

$$L(\theta) - L(\theta^{(t)}) = \ln \left(\sum_z p(Y|z, \theta) p(z|\theta) \right) - \ln p(Y|\theta^{(t)})$$

$$= \ln \left(\sum_z p(z|Y, \theta^{(t)}) \frac{p(Y|z, \theta) p(z|\theta)}{p(z|Y, \theta^{(t)})} \right) - \ln p(Y|\theta^{(t)})$$

利用琴生不等式可得:

$$\geq \sum_z p(z|Y, \theta^{(t)}) \ln \frac{p(Y|z, \theta) p(z|\theta)}{p(z|Y, \theta^{(t)})} - \ln p(Y|\theta^{(t)})$$

$$L(\theta) - L(\theta^{(t)}) \geq \sum_z p(z|Y, \theta^{(t)}) \ln \frac{p(Y|z, \theta) p(z|\theta)}{p(z|Y, \theta^{(t)})} - \sum_z p(z|Y, \theta^{(t)}) \ln p(Y|\theta^{(t)})$$

$$= \sum_z p(z|Y, \theta^{(t)}) \left(\ln \frac{p(Y|z, \theta) p(z|\theta)}{p(z|Y, \theta^{(t)})} - \ln p(Y|\theta^{(t)}) \right)$$

$$= \sum_z p(z|Y, \theta^{(t)}) \ln \frac{p(Y|z, \theta) p(z|\theta)}{p(z|Y, \theta^{(t)}) p(Y|\theta^{(t)})}$$

$$\text{令 } B(\theta, \theta^{(t)}) = L(\theta^{(t)}) + \sum_z p(z|Y, \theta^{(t)}) \ln \frac{p(Y|z, \theta) p(z|\theta)}{p(z|Y, \theta^{(t)}) p(Y|\theta^{(t)})}$$

$$\text{则 } L(\theta) \geq B(\theta, \theta^{(t)})$$

$$B(\theta^{(t)}, \theta^{(t)}) \geq B(\theta^{(t)}, \theta^{(t)})$$

由于 $B(\theta^{(t)}, \theta^{(t)}) = L(\theta^{(t)})$, 所以可以进一步得到:

$$L(\theta^{(t+1)}) \geq B(\theta^{(t)}, \theta^{(t)}) \geq B(\theta^{(t)}, \theta^{(t)}) = L(\theta^{(t)})$$

NO.

DATE

(4)

因此,任何可以使 $B(\theta, \theta^{(i)})$ 增大的 θ , 也可以使 $L(\theta)$ 增大, 于是问题转化为了求解能使得 $B(\theta, \theta^{(i)})$ 达到极大的 $\theta^{(i+1)}$, 即

$$\theta^{(i+1)} = \arg \max_{\theta} B(\theta, \theta^{(i)})$$

$$= \arg \max_{\theta} (L(\theta^{(i)}) + \sum_{\mathbf{z}} P(\mathbf{z}|\mathbf{y}, \theta^{(i)}) \ln \frac{P(\mathbf{y}|\mathbf{z}, \theta) P(\mathbf{z}|\theta)}{P(\mathbf{z}|\mathbf{y}, \theta^{(i)}) P(\mathbf{y}|\theta^{(i)})})$$

$$= \arg \max_{\theta} (\sum_{\mathbf{z}} P(\mathbf{z}|\mathbf{y}, \theta^{(i)}) \ln (P(\mathbf{y}|\mathbf{z}, \theta) P(\mathbf{z}|\theta)))$$

$$= \arg \max_{\theta} (\sum_{\mathbf{z}} P(\mathbf{z}|\mathbf{y}, \theta^{(i)}) (\ln P(\mathbf{y}, \mathbf{z}|\theta)))$$

$$= \arg \max_{\theta} Q(\theta, \theta^{(i)})$$

式 7.37